基於單一樣本學習技術之課堂點名系統

林玟君，李郁含，徐文心，余執彰
中原大學資訊工程系
E-mail: s10927159@cycu.edu.tw
E-mail: s10833230@cycu.edu.tw
E-mail: s10911151@cycu.edu.tw
E-mail: chihchangyu@cycu.org.tw

摘要

本研究旨在深入探討基於單一樣本學習技術的人臉辨識點名系統。鑒於資料集的數量不足是目前深度學習領域的一大挑戰，傳統的機器學習策略在少樣本數據下難以達到理想效果。在參考過去學者提出的相關文獻後，我們採用了數據增強、特徵學習、遷移學習，再結合三重網路以及 simCLR，透過不同以往的做法，我們引入集成學習策略，目的在於結合不同模型，進一步增強模型的預測能力和穩定性。實驗結果顯示，限定正臉照且人數為 20 的條件下，相較於單一模型之預測，集成方法確實為整體精確度帶來 5%至 20%提升，且在預測自行蒐集的資料集以及 CelebA 資料集，模型精確度達到了約 80%至 90%。此實驗數據支持本研究所提出之方法確實能夠增強系統的泛化性能，並提高了模型的預測能力及穩定性。

關鍵字：單一樣本學習、遷移學習、孿生網路、三重網絡、simCLR、集成學習。

1. 前言

在當前的資訊科技與硬體技術快速發展下，數十億的智慧型裝置已於多個領域形成一密集的互聯網絡。這種網絡化趨勢在醫療、交通、工業生產以及家庭自動化等基礎設施中尤為明顯。雖然這些裝置能夠收集大量的數據，但在特定的情境下的數據數量往往有限。加上因隱私及倫理的問題，深度學習所需的數據樣本往往不足。在這樣的限制下，如何克服困境，達到逼近大數據深度學習的效果已成為學術界的重要課題。此問題更進一步延伸至教育領域，例如課堂點名。儘管唱名及 QRcode 點名方法存在，但它們各自帶有時間效率及公平性的問題。因此，本研究提議採用人臉辨識系統來優化點名程序。考慮到基於傳統機器學習的人臉辨識通常需要多張照片來訓練，而在實際情境中向每位學生蒐集多張照片會使資料蒐集的過程過於冗長，且缺乏效率，因此本研究欲進一步探索僅使用單張照片建立一具高精確度的點名系統的可能性，也就是單一樣本學習（One-shot Learning）的問題。

單一樣本學習可以在資料集稀缺的環境中實現有效的學習，因不需要依賴於大型數據，能夠降低訓練成本，不僅如此，單一樣本學習能夠在新數據出現時迅速更新模型，快速適應新情境，且它的學習方式更接近人類，能夠從少量的例子中迅速學習新概念。然而，在傳統深度學習中，模型的訓練通常依賴於大量的數據集，這種學習方式在資料量不足的情況下面臨多種挑戰。首先，由於資料稀缺，模型有很高的風險會過度擬合到少數樣本上，影響其泛化能力，使其不容易適應於不熟悉的數據或場景。其次，會導致資料集的特徵選擇困難，難以確定哪些是有價值的特徵。最後，模型容易受到不均衡的資料分部影響，而導致模型產生偏見。這也意味著我們需要不同於以往的機器學習模式，來解決目前的困境。

在參考了 Song 等人於 2022 年發表的論文[1]中歸納了近幾年與少樣本學習（Few-shot Learning）有關的文獻資料，當中提到了少樣本學習目前所面臨的困境及解決方法。基於人臉辨識領域上的單一樣本問題，不同於過往的方法，本研究最後決定採用集成方法（Ensemble Learning）[2]結合了三重網路(Triplet Network)[3]以及 simCLR[4]的技術，來應對資料集不足可能會出現的問題。由於三重網路以及 simCLR 的重點在於特徵學習，而不僅僅是分類，使少樣本在特徵空間中有更好的表示。且集成方法由多個組合模型的預測產生一個終極預測結果，可減少單一模型對少量樣本過度依賴，從而減少過度擬合的風險。透過實驗顯示，本研究方法所貢獻的優點如下：

1. 運用三重網路以及 simCLR 兩者結合集成方法可以擁有更強大的特徵提取，且提高模型的容錯能力，確保整體系統的穩定性。
2. 由於不同模型可能專注於資料的不同方面，從中獲取獨特的洞察，並提高預測準確性。
3. 透過集成學習的方式來減少單一模型過度擬合的狀況，提高模型的泛化能力。

總之，本研究的方法提供了一個新的視角來看待人臉辨識中的單一樣本問題，且透過實驗數據也可證實具有一定的參考價值。

2. 實驗方法

本研究所提出的基於單一樣本學習之點名系統的主要流程為資料集準備、數據增強（Data Augmentation）、遷移學習（Transfer Learning）

[5]，結合三重損失（Triplet Loss）以及對比損失（Contrastive Loss），最後以集成方法來進行投票。圖 1. 為本研究之演算法流程。

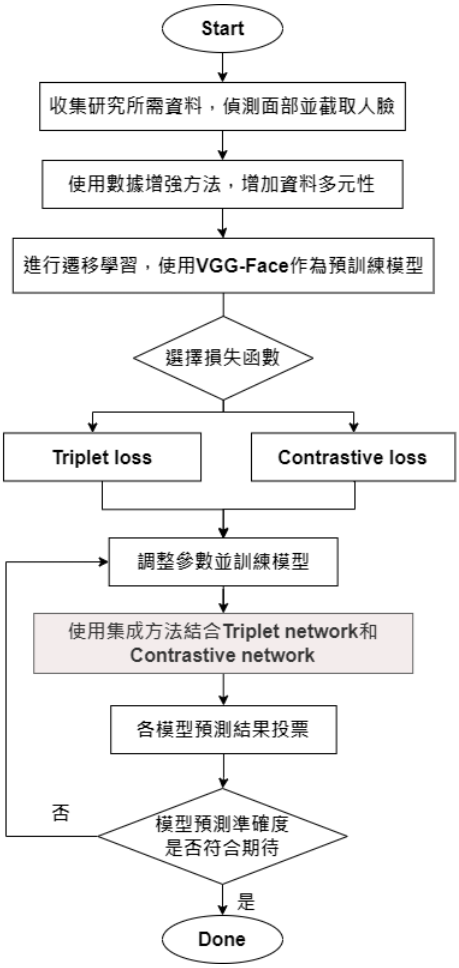

圖 1. 演算法流程

2.1 資料集準備

2.1.1 資料集之建構

鑑於單一樣本學習對於照片內容之敏感性，不同的表情抑或拍攝角度均可能極大地影響預測結果。因此，本研究將所收集之資料集依難度分為三類，詳情載於下表 1。此舉旨在確保實驗數據之可靠性與廣泛的參考價值。

表 1. 驗證測試及資料難度

難度	等級 1	等級 2	等級 3
表情/角度	正臉/微歪頭、微笑	正臉/歪頭露齒笑、微轉頭	轉頭、戴眼鏡、大笑
範例	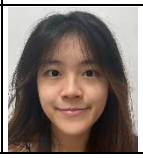		

2.1.2 人臉區域擷取

為排除背景雜訊對測量誤差所帶來的影響，本研究倚賴 Google Research 所研發之多媒體機器學習模型——MediaPipe 中的人臉偵測模型，用以擷取人臉之特徵。且為確保研究內容之一致性，我們將所採集之照片統一調整為 224*224 像素之尺寸。

2.2 數據增強技術

在面對有限的訓練資料時，模型容易陷入過度擬合現象，即便在訓練資料上取得優異表現，對於未曾見過的資料可能無法保持相同程度的準確性。為了應對這一問題，本研究使用了數據增強的技術，對資料隨機進行旋轉、平移、剪切、縮放、水平翻轉、亮度調整、通道移位等處理，增加數據多樣性。同時，為了提升模型的泛化能力與穩定性，以及減少過度擬合的風險，我們還加入了高斯噪聲（Gaussian Noise）和高斯模糊（Gaussian Blur）等技術，進一步增加對訓練樣本的多樣性處理。

2.3 遷移學習

於數據增強之後，雖然資料集之多樣性有了顯著的提升，但其量仍不足以完全支撐一個大規模的人臉辨識深度學習網絡自底向上的訓練。針對此困境，我們採用了遷移學習策略，從而避免了從零開始的網絡訓練過程。在本研究的架構中，我們選定 VGG-Face 神經網絡[6]作為我們的預訓練特徵抽取器，如圖 2 所示的神經網路架構。通過將該模型的部分層設置為不可訓練狀態，保留了 VGG-Face 網絡所擁有的核心知識。

圖 2. VGG-Face 之神經網路架構

然而，當資料量不足，現有樣本不僅無法很好的代表整個資料的分布，也無法確定哪些特徵是最具有意義的。此外，傳統機器學習模型若太過複雜，可能也會在少量的資料上過度擬合。因此，我們移除了預訓練模型的原始分類器，並新增了兩層神經網絡，並以圖片之特徵向量作為模型之輸出。

為了深入探討單一樣本學習的挑戰，本研究基於此遷移學習策略，建立了三重網路及 simCLR。這兩種網路架構都是孿生網路（Siamese Networks）[7]的一種變體，它們都屬於深度學習中的特徵學習方法，用於學習如何比較樣本之間的相似性或差異性，我們將在接下來的兩個小節

中進行詳細的理論探討與分析。下圖 3 為遷移學習之神經網路架構。

圖 3. 網路架構（以 Triplet Loss 為例）

2.4 三重網路

三重網路是一種特殊的孿生網路結構，由三個共享權重的子網路組成，而每一個子網路都基於 2.3 的遷移學習模型進行設計，且都接收一個輸入。這三個輸入被稱為：錨點（Anchor）、正例（Positive）和負例（Negative）。錨點是我們要描述的對象；正例是與錨點相似的對象；而負例是與錨點不相似的對象。圖 4 為三重網路之神經網路架構。

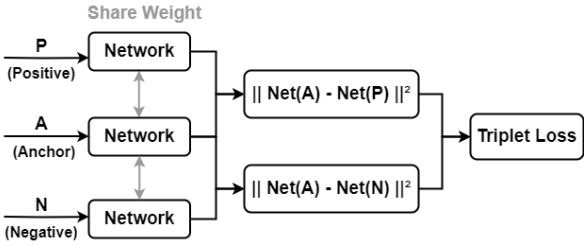

圖 4. 三重網路架構

我們希望錨點的嵌入與正例的嵌入相似，並且希望錨點的嵌入與負例的嵌入不相似。而三重損失函數（Triplet Loss Function）的目的就是要縮小錨點和正例的距離，同時最大化錨點和負例之間的距離差距。損失函數公式為：

$$L(A,P,N) = d(A,P) - d(A,N) + margin, 0) \quad (1)$$

其中，A 為錨點，P 為正例，N 為負例，d 表示距離，margin 為一個超參數[8]，用來確保錨點和正例之間的距離至少比錨點和負例之間的距離小 margin。

2.5 SimCLR

在眾多的深度學習網路架構中，三重網路經常被提及於單一樣本學習的文獻中。然而，為了瞭解此領域中其他可能的優化策略，本研究進一步探討了 simCLR 在單一樣本學習中的效能。

simCLR 是自監督學習的一種（Self-Supervise Learning）[3]，其核心思想是將相近的數據拉近，將不相近的數據推遠。simCLR 通常由兩個共享權重的子網路組成，而此子網路亦基於 2.3 的遷移學習模型進行設計，且都接收一個輸入。這兩個輸入通常代表一對數據樣本。圖 5 為 simCLR 之神經網路架構。

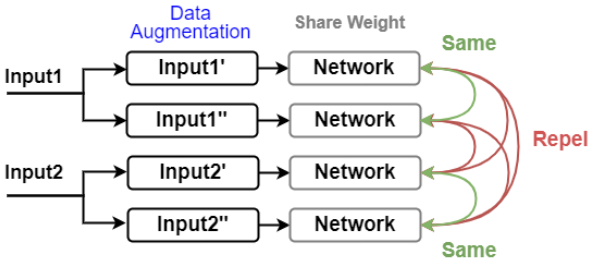

圖 5. simCLR 架構

對比損失函數（Contrastive Loss Function）目的是最小化相似樣本間的距離，並最大化不相似樣本間的距離。對比損失函數公式為：

$$L = \Sigma(1-Y) * D^2 + Y * max\,(0, \alpha - D)^2 \quad (2)$$

其中，D 是兩個樣本的特徵向量間的歐氏距離，Y 是一個二進制標籤（如果兩個樣本相似則為 1，不相似則為 0），α 是一個閾值，代表當兩個樣本不相似時，他們的距離至少應該達到多少。當兩個樣本相似時，我們希望他們的距離 D 越小越好；當兩個樣本不相似時，我們希望他們的距離至少大於 α。

2.6 集成學習

集成學習是機器學習中的一種策略，其主要思想是通過組合多個學習模型來改善整體性能。而不是只依賴單一模型，集成學習結合了多個模型的預測結果，從而獲得比任何單一模型更好的性能。

在我們的初步實驗中，我們發現單一模型經常出現過度擬合或是樣本類別數量不平衡的現象，導致其預測穩定性受到影響，進而降低其可信賴性。值得注意的是，在比對三重網路與 simCLR 的預測結果時，我們發現這兩種網路在同一數據集上展現出獨特且互補的預測能力，如下圖 6 及圖 7 所示，兩張圖片都是基於 CelebA 資料集，其中，縱軸表示人數，橫軸表示每人有 6 張圖片；Model1 表示 Triplet Network，Model2 表示 simCLR；綠色格子表示兩個模型皆預測正確，黑色格子表示兩個模型皆預測錯誤，藍色格子表示 Model2 預測正確而 Model1 預測錯誤，紅色格子表示 Model2 預測錯誤而 Model1 預測正確。圖中所標示成紅色及藍色的部分即為兩模型互補預測的部分，也證實了兩神經網路皆有自己獨特的學習方式和錯誤模式，可以相互補償彼此的弱點。

結合上述兩點原因，本研究決定採用集成學習以及硬投票機制（Hard Voting）[9]，不依靠單一模型的預測結果，而是結合了多個不同的模型，使多模型的組合能夠比單一模型具有更好的泛化能力，以及更高的穩定度。

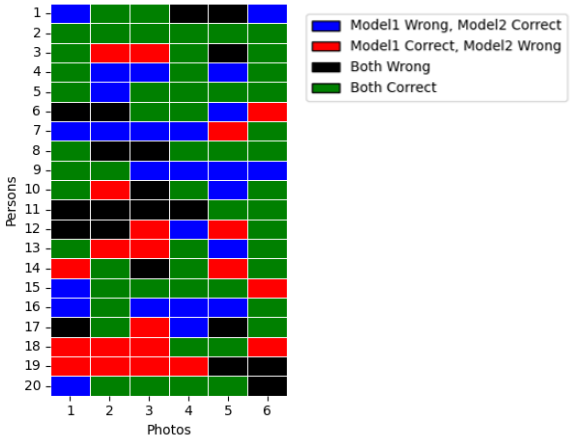

圖 6. 兩種模型的預測結果比較
（資料難度為等級 3，預測人數為 20 人）

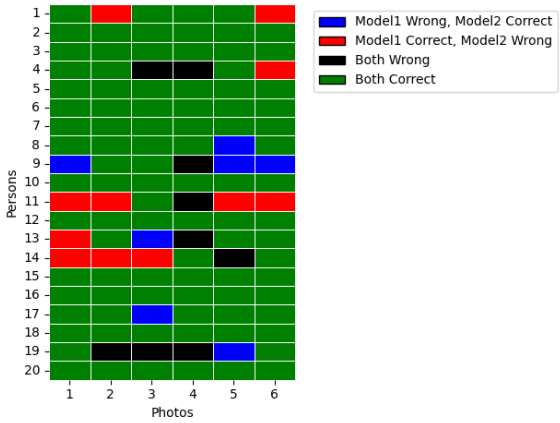

圖 7. 兩種模型的預測結果比較
（資料難度為等級 1，預測人數為 20 人）

在我們的研究中，我們採用了一個由十個獨立訓練的模型所組成的硬投票系統。其中，五個模型基於三重網路架構，另五個則基於 simCLR 架構。每次進行訓練時，皆會調整數據增強參數以集隨機抽樣的方法，以確保每輪模型的訓練不依賴於相同的資料。在模型預測階段，我們綜合了這十個模型的預測結果，並採用硬投票機制，最終預測結果則是基於得票數最多的類別。在出現投票數量相同的情況下，我們使用模型的預測精確度作為加權因子，以決定哪一個預測結果應作為最終輸出。若在進行加權後仍出現平票情況，我們則採用隨機選擇的方法來確定最終的預測輸出。

3. 實驗結果與分析

為了訓練和評估我們的模型，並提供有說服力以及參考價值的實驗結果，我們使用了兩種資料來源：首先是自家拍攝的資料集，這部分的資料涵蓋了實際應用場景中可能遇到的各種情況；另外，我們也引入了 CelebA 資料集以及網路上公開的資料集，利用其豐富的樣本進一步強化我們的模型。

每個不同的標籤皆有 1 張訓練集，6 張驗證集，以集 6 張測試集。為了探討與觀察不同人數和資料難度對模型精確度的影響，我們沒有設定固定的 batch size 和資料集樣本數。

在軟體方面，我們使用了 Python 3.10.12 和 TensorFlow 2.12.0。為了優化模型，我們採用了 Adam 作為優化器，並設置學習率為 0.0001。迭代大小為 30 次，為了確保模型不會過度擬合，我們實施了早期停止策略：若在 3 個 Epoch 內驗證集的損失持續上升，我們便終止訓練。最終，我們使用分類的精確度作為評估模型性能的主要指標。

3.1 模型評估表現

透過實驗驗證，如圖 8（基於自訂資料集）和圖 9（基於 CelebA 資料集）所示，不論在何種資料集背景之下，我們均能夠觀測到集成學習對模型性能帶來的明顯提升。與單一模型相比，採用集成學習策略後，模型在穩定度和精確度方面均獲得了顯著改善。這些實驗結果不僅確認了三重網路和 simCLR 在獨立運行時各自的優越性，還揭示了它們在結合運用後能進一步增強模型的預測能力和穩定性。

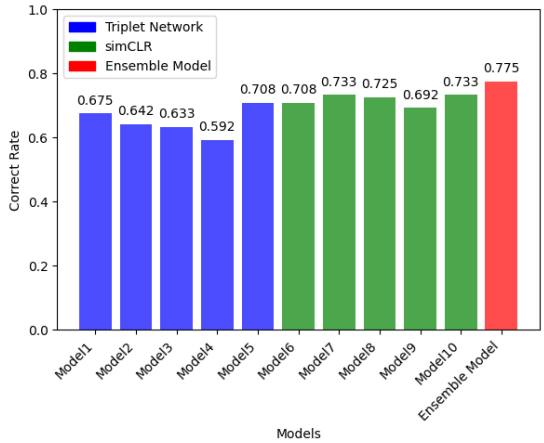

圖 8. 自訂資料集的模型精確度比較圖
（資料難度為等級 2，預測人數為 20 人）

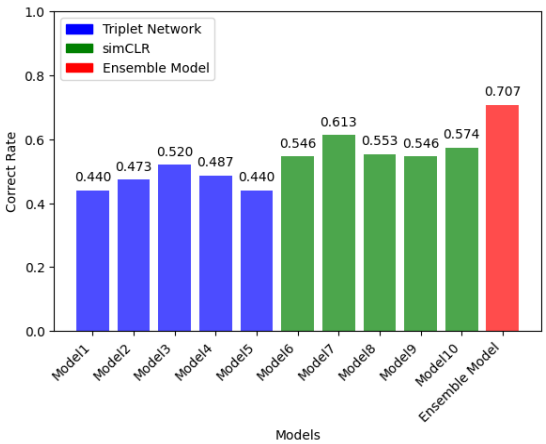

圖 9. CelebA 資料集的模型精確度比較圖
（資料難度為等級 2，預測人數為 25 人）

3.2 人數變動對於精確度的影響

如下圖 10（基於自訂資料集）和圖 11（基於 CelebA 資料集）所示，在資料集難度統一為等級 2 的情況下，模型精確度隨著人數增加，大致呈現下降的趨勢。

這種現象可以歸因於以下兩點。首先，當人數增加時，要辨識的人臉特徵變得更加多樣化，這意味著模型需要足夠多的訓練數據來覆蓋更多的變化和面孔。其次，人數增加也會導致模型的複雜度以及訓練時間的增加，使訓練過程會更加困難，進一步影響模型的精確度。特別值得注意的是，在單一樣本的條件下，上述的情況可能會顯得更加嚴重，因此精確度隨著人數增加而下降是正常且可預期的現象。

特別值得注意的是，在圖 11 中人數為 30 人的情況下，可以觀察到測試集精確度高於驗證集精確度的特殊情況，由於在資料集非常小的情況下，稍微的隨機差異也可能導致性能大幅度波動，且更容易受到資料分布不均的影響。如果模型剛好適應了測試集的特點而不是驗證集的特點，那麼它在測試集上的表現可能會更好。

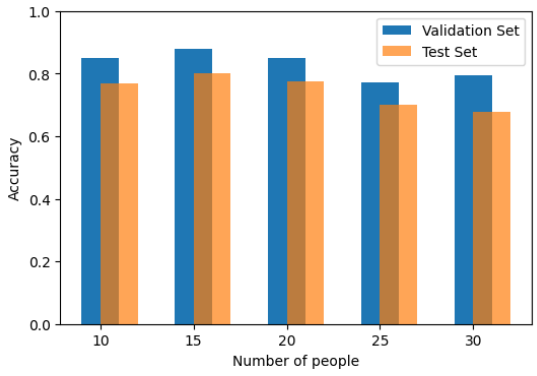

圖 10. 自訂資料集在不同人數對精確度的影響

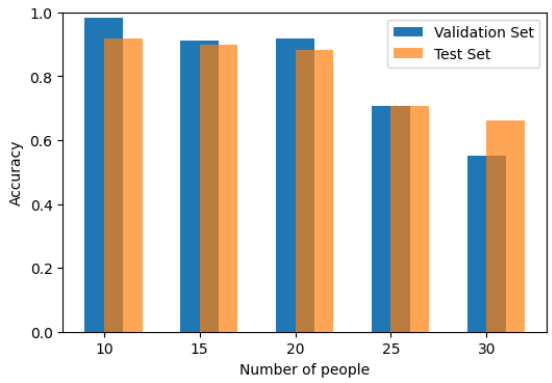

圖 11. CelebA 資料集在不同人數對精確度的影響

3.3 資料難度對於精確度的影響

根據實驗數據，如下圖 12（基於自訂資料集）和圖 13（基於 CelebA 資料集）所示，固定人數為 20 人的情境下觀察，當資料難度逐漸上升時，精確度呈現下降趨勢。這種精確度下降現象歸因於資料的增加難度導致不確定性的提高，使模型難以確定哪些特徵在面對更具挑戰性的圖像時仍然具有真實性。特別值得注意的是，在單一樣本學習情境下，由於樣本數量相當有限，模型無法充分學習個體的面部特徵，容易發生過度擬合的現象。為了克服這些挑戰，本研究采取的數據增強技術，針對臉部傾斜照片的處理，取得了良好的識別能力。

由圖 12 可以觀察到，當資料集的難度由等級 1 升至等級 2 時，精確度下降幅度相對較小，這歸因於數據擴充技術在處理臉部傾斜照片方面表現出尚佳識別能力。然而，當資料難度進一步提高，即從等級 2 升至等級 3 時，精確度下降幅度變得更為明顯，這主要受到不同面部角度和戴有臉部遮蔽物的照片所帶來的挑戰影響，這些因素對模型的精確度依然造成限制。

然而，根據圖 13 所示之實驗數據，資料難度為等級 1 的精確度並未高於資料難度為等級 2 的精確度，推測原因為前者資料集中照片解析度較低，即使皆為正臉的照片，但受到畫質影響，導致即使圖片之表情和角度即使變化較少，但精確度仍然低於難度為等級 2 的資料集。此實驗結果也提醒我們，在進行人臉識別時，除了須考慮角度及表情等因素以外，圖片的畫質也會對預測結果造成一定程度的影響。

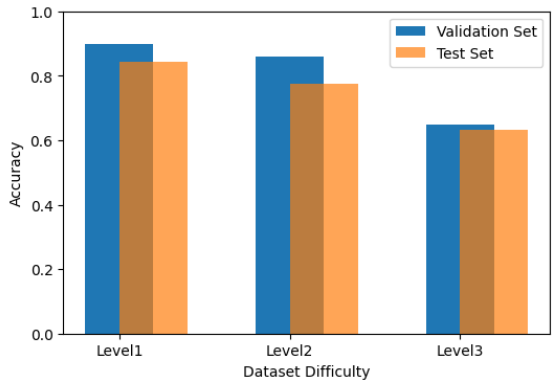

圖 12. 自訂資料集在不同資料難度對精確度的影響

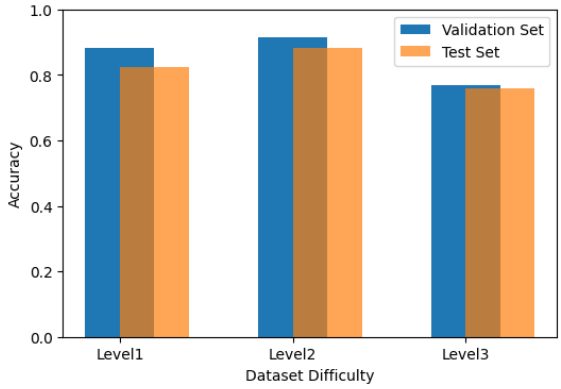

圖 13. CelebA 資料集在不同資料難度對精確度的影響

3.4 對比網絡與三重網絡的模型表現之差異探討

根據先前的實驗數據，如圖 8 和圖 9 所示，我們可以觀察到，simCLR 的精確度普遍優於三重網絡。simCLR 和三重網絡都是深度學習架構，用於學習特徵表示。這兩種模型都旨在使相似的樣本在特徵空間中更接近，而不相似的樣本則更遠，但它們使用不同的方法來實現這一目標，這導致了它們在本研究中的性能差異。

simCLR 擁有更簡單的訓練過程，模型只需比對正樣本和負樣本，而不必關注多個樣本之間的關係。這使得模型更容易訓練，有能力學習差異性特徵，同時減少了訓練過程的複雜性，並提高了計算效率。

相比之下，三重網路除了模型相對複雜外，還需要精心選擇適當的三元組樣本（錨點、正樣本、負樣本）。不當的樣本選擇可能會干擾訓練過程。此外，三重損失中的 margin 參數需要仔細調整，以確保正樣本和負樣本之間有足夠的差異。

總之，simCLR 在單一樣本學習情境下的優勢可能來自於其更簡單、穩定且易於控制的訓練過程，從而提高了精確度。即使如此，三重網路和 simCLR 在獨立運行時依舊有各自的優越性，使兩模型之間能夠在進行集成方法時達到互補的效果。

4. 總結

本研究旨在探討基於單一樣本學習的人臉點名系統在實際應用中的效能和挑戰。通過一系列實驗和分析，我們獲得了以下主要結論和洞察：

我們的研究結果顯示，將三重網路、simCLR 和集成學習結合的單一樣本學習技術能夠在人臉點名系統中取得優異的表現。這種方法利用學習到的距離度量，能夠在僅有少數樣本的情況下，實現高精度的人臉識別，減少了人臉數據集的依賴性，且在面對新的、以前未見過的目標時展現出色的識別性能，克服了傳統深度學習方法在少數樣本情況下的困難。這對於實際場景中的人臉點名系統具有重要意義，尤其是在人臉數據有限或不平衡的情況下。

我們的研究還指出了單一樣本學習的一些挑戰，如模型的穩定性和泛化能力。儘管在特定情境下表現出色，但這種方法仍然可能對樣本的多樣性和不同攝影條件的變化有著一定程度的敏感性。因此在實際應用中需要更多地考慮不同場景下的模型表現，並適時進行模型調整和優化。

未來的研究可以進一步探討更多的集成學習和不同的單一樣本學習技術，以及如何結合多種特徵和信息源以提高點名系統的準確性。

總之，基於三重網路、simCLR，和集成方法的單一樣本學習技術為人臉點名系統帶來了新的可能性。我們的研究成果為評估這種技術的效能和挑戰提供了有參考價值的見解，並為在實際教育場景中的應用提供了有益的指導。

5. 參考文獻

[1] Yisheng Song, Ting Wang, Subrota K Mondal, Jyoti Prakash Sahoo, “A Comprehensive Survey of Few-Shot Learning: Evolution, Applications, Challenges, and Opportunities.”, 2022

[2] M.A. Ganaie, Minghui Hu, A.K. Malik, M. Tanveer, P.N. Suganthan, “Ensemble deep learning: A review”, 2021

[3] Florian Schroff, Dmitry Kalenichenko, James Philbin. “FaceNet: A Unified Embedding for Face Recognition and Clustering”, 2015

[4] Ting Chen, Simon Kornblith, Mohammad Norouzi, Geoffrey Hinton, “A Simple Framework for Contrastive Learning of Visual Representations”, 2020

[5] Fuzhen Zhuang, Zhiyuan Qi, Keyu Duan, Dongbo Xi, Yongchun Zhu, Hengshu Zhu, Hui Xiong, Qing He, “A Comprehensive Survey on Transfer Learning”, 2019

[6] Omkar M. Parkhi, Andrea Vedaldi and Andrew Zisserman. “Deep Face Recognition”, 2015

[7] Elad Hoffer, Nir Ailon. ”Deep Metric Learning Using Triplet Network.”, 2014

[8] Weihua Chen, Xiaotang Chen, Jianguo Zhang, Kaiqi Huang. “Beyond triplet loss: a deep quadruplet network for person re-identification”, 2017

[9] Jason Brownlee, “How to Develop Voting Ensembles With Python” , 2021

6. 致謝

感謝國家科學及技術委員會對於本研究（計畫編號：112-2813-C-033-007-E）的研究補助經費。